

1.2 HARDWARE DE RED

Ahora es tiempo de dejar a un lado las aplicaciones y los aspectos sociales de las redes para enfocarnos en las cuestiones técnicas implicadas en su diseño. No existe una clasificación aceptada en la que encajen todas las redes, pero hay dos que sobresalen de manera importante: la tecnología de transmisión y la escala. Examinaremos ahora cada una de ellas por turno.

Hablando en sentido general, existen dos tipos de tecnología de transmisión que se emplean mucho en la actualidad: los enlaces de **difusión** (*broadcast*) y los enlaces de **punto a punto**.

Los enlaces de punto a punto conectan pares individuales de máquinas. Para ir del origen al destino en una red formada por enlaces de punto a punto, los mensajes cortos (conocidos como **paquetes** en ciertos contextos) tal vez tengan primero que visitar una o más máquinas intermedias. A menudo es posible usar varias rutas de distintas longitudes, por lo que es importante encontrar las más adecuadas en las redes de punto a punto. A la transmisión punto a punto en donde sólo hay un emisor y un receptor se le conoce como **unidifusión** (*unicasting*).

Por el contrario, en una red de difusión todas las máquinas en la red comparten el canal de comunicación; los paquetes que envía una máquina son recibidos por todas las demás. Un campo de dirección dentro de cada paquete especifica a quién se dirige. Cuando una máquina recibe un paquete, verifica el campo de dirección. Si el paquete está destinado a la máquina receptora, ésta procesa el paquete; si el paquete está destinado para otra máquina, sólo lo ignora.

Una red inalámbrica es un ejemplo común de un enlace de difusión, en donde la comunicación se comparte a través de una región de cobertura que depende del canal inalámbrico y de la máquina que va a transmitir. Como analogía considere alguien parado en una sala de juntas gritando: “Watson, ven aquí. Te necesito”. Aunque muchas personas hayan recibido (escuchado) el paquete, sólo Watson responderá; los otros simplemente lo ignorarán.

Por lo general, los sistemas de difusión también brindan la posibilidad de enviar un paquete a *todos* los destinos mediante el uso de un código especial en el campo de dirección. Cuando se transmite un paquete con este código, todas las máquinas en la red lo reciben y procesan. A este modo de operación se le conoce como **difusión** (*broadcasting*). Algunos sistemas de difusión también soportan la transmisión a un subconjunto de máquinas, lo cual se conoce como **multidifusión** (*multicasting*).

Hay un criterio alternativo para clasificar las redes: por su escala. La distancia es importante como medida de clasificación, ya que las distintas tecnologías se utilizan a diferentes escalas.

En la figura 1-6 clasificamos los sistemas multiprocesadores con base en su tamaño físico. En la parte de arriba están las redes de área personal, las cuales están destinadas a una persona. Después se encuentran redes más grandes. Éstas se pueden dividir en redes de área local, de área metropolitana y de área amplia, cada una con una escala mayor que la anterior. Por último, a la conexión de dos o más redes se le conoce como **interred** (*internetwork*). La Internet de nivel mundial es sin duda el mejor ejemplo (aunque no el único) de una interred. Pronto tendremos interredes aún más grandes con la **Internet interplanetaria** que conecta redes a través del espacio (Burleigh y colaboradores, 2003).

En este libro hablaremos sobre las redes de todas estas escalas. En las siguientes secciones le proporcionaremos una breve introducción al hardware de red con base en la escala.

1.2.1 Redes de área personal

Las **redes de área personal**, generalmente llamadas **PAN** (*Personal Area Network*) permiten a los dispositivos comunicarse dentro del rango de una persona. Un ejemplo común es una red inalámbrica que conecta a una computadora con sus periféricos. Casi todas las computadoras tienen conectado un monitor, un teclado, un ratón y una impresora. Sin la tecnología inalámbrica es necesario realizar esta conexión

Distancia entre procesadores	Procesadores ubicados en el (la) mismo(a)	Ejemplo
1 m	Metro cuadrado	Red de área personal
10 m	Cuarto	
100 m	Edificio	Red de área local
1 km	Campus	
10 km	Ciudad	Red de área metropolitana
100 km	País	
1000 km	Continente	Red de área amplia
10000 km	Planeta	
		Internet

Figura 1-6. Clasificación de los procesadores interconectados con base en la escala.

mediante cables. Hay tantos usuarios nuevos que batallan mucho para encontrar los cables adecuados y conectarlos en los orificios apropiados (aun cuando, por lo general, están codificados por colores), que la mayoría de los distribuidores de computadoras ofrecen la opción de enviar un técnico al hogar del usuario para que se encargue de ello. Para ayudar a estos usuarios, algunas empresas se pusieron de acuerdo para diseñar una red inalámbrica de corto alcance conocida como **Bluetooth** para conectar estos componentes sin necesidad de cables. La idea es que si sus dispositivos tienen Bluetooth, no necesitará cables. Sólo hay que ponerlos en el lugar apropiado, encenderlos y trabajarán en conjunto. Para muchas personas, esta facilidad de operación es una gran ventaja.

En su forma más simple, las redes Bluetooth utilizan el paradigma maestro-esclavo de la figura 1-7. La unidad del sistema (la PC), por lo general es el maestro que trata con el ratón, el teclado, etc., como sus esclavos. El maestro dice a los esclavos qué direcciones usar, cuándo pueden transmitir información, durante cuánto tiempo pueden transmitir, qué frecuencias usar, etcétera.

También podemos usar Bluetooth en otras aplicaciones. A menudo se utiliza para conectar unos audífonos a un teléfono móvil sin cables, además se puede conectar el reproductor musical digital a nuestro automóvil con sólo tenerlo dentro del rango. Una clase completamente distinta de red PAN se forma




Figura 1-7. Configuración de red PAN con Bluetooth.

cuando un dispositivo médico integrado, como un marcapasos, bomba de insulina o audífono para discapacitados se comunica con un control remoto operado por el usuario. En el capítulo 4 veremos con detalle la tecnología Bluetooth.

Las redes PAN también se pueden construir con otras tecnologías que se comunican dentro de rangos cortos, como RFID en las tarjetas inteligentes y los libros de las bibliotecas. En el capítulo 4 estudiaremos la tecnología RFID.

1.2.2 Redes de área local

Las **redes de área local**, generalmente llamadas **LAN** (*Local Area Networks*), son redes de propiedad privada que operan dentro de un solo edificio, como una casa, oficina o fábrica. Las redes LAN se utilizan ampliamente para conectar computadoras personales y electrodomésticos con el fin de compartir recursos (por ejemplo, impresoras) e intercambiar información. Cuando las empresas utilizan redes LAN se les conoce como **redes empresariales**.

Las redes LAN son muy populares en la actualidad, en especial en los hogares, los edificios de oficinas antiguos, las cafeterías y demás sitios en donde es muy problemático instalar cables. En estos sistemas, cada computadora tiene un módem y una antena que utiliza para comunicarse con otras computadoras. En la mayoría de los casos, cada computadora se comunica con un dispositivo en el techo, como se muestra en la figura 1-8(a). A este dispositivo se le denomina **AP (Punto de Acceso, del inglés Access Point)**, **enrutador inalámbrico** o **estación base**; transmite paquetes entre las computadoras inalámbricas y también entre éstas e Internet. El AP es como el niño popular de la escuela, ya que todos quieren hablar con él. Pero si hay otras computadoras que estén lo bastante cerca una de otra, se pueden comunicar directamente entre sí en una configuración de igual a igual.

Hay un estándar para las redes LAN inalámbricas llamado **IEEE 802.11**, mejor conocido como **WiFi**. Opera a velocidades desde 11 hasta cientos de Mbps (en este libro nos apegaremos a la tradición y mediremos las velocidades de las líneas de transmisión en megabits/segundo, en donde 1 Mbps es 1 000 000 bits/segundo, y en gigabits/segundo, en donde 1 Gbps es 1 000 000 000 bits/segundo). En el capítulo 4 hablaremos sobre el estándar 802.11.

Las redes LAN alámbricas utilizan distintas tecnologías de transmisión. La mayoría utilizan cables de cobre, pero algunas usan fibra óptica. Las redes LAN tienen restricciones en cuanto a su tamaño, lo cual significa que el tiempo de transmisión en el peor de los casos es limitado y se sabe de antemano. Conocer estos límites facilita la tarea del diseño de los protocolos de red. Por lo general las redes LAN alámbricas que operan a velocidades que van de los 100 Mbps hasta un 1 Gbps, tienen retardo bajo (microsegundos




Figura 1-8. Redes inalámbrica y alámbrica. (a) 802.11. (b) Ethernet conmutada.

o nanosegundos) y cometen muy pocos errores. Las redes LAN más recientes pueden operar a una velocidad de hasta 10 Gbps. En comparación con las redes inalámbricas, las redes LAN alámbricas son mucho mejores en cuanto al rendimiento, ya que es más fácil enviar señales a través de un cable o fibra que por el aire.

La topología de muchas redes LAN alámbricas está basada en los enlaces de punto a punto. El estándar IEEE 802.3, comúnmente conocido como **Ethernet**, es hasta ahora el tipo más común de LAN alámbrica. La figura 1-8(b) muestra un ejemplo de topología de **Ethernet conmutada**. Cada computadora se comunica mediante el protocolo Ethernet y se conecta a una caja conocida como **switch** con un enlace de punto a punto. De aquí que tenga ese nombre. Un switch tiene varios **puertos**, cada uno de los cuales se puede conectar a una computadora. El trabajo del switch es transmitir paquetes entre las computadoras conectadas a él, y utiliza la dirección en cada paquete para determinar a qué computadora se lo debe enviar.

Para crear redes LAN más grandes se pueden conectar switches entre sí mediante sus puertos. ¿Qué ocurre si los conectamos en un circuito cerrado? ¿Podrá funcionar la red así? Por fortuna, los diseñadores consideraron este caso. Es responsabilidad del protocolo determinar qué rutas deben recorrer los paquetes para llegar de manera segura a la computadora de destino. En el capítulo 4 veremos cómo funciona esto.

También es posible dividir una gran LAN física en dos redes LAN lógicas más pequeñas. Tal vez se pregunte por qué sería esto útil. En ocasiones la distribución del equipo de red no coincide con la estructura de la organización. Por ejemplo, los departamentos de ingeniería y finanzas de una empresa podrían tener computadoras en la misma LAN física debido a que se encuentran en la misma ala del edificio, pero podría ser más sencillo administrar el sistema si cada departamento tuviera su propia red lógica, denominada **LAN virtual** o **VLAN**. En este diseño cada puerto se identifica con un “color”; por ejemplo, verde para ingeniería y rojo para finanzas. Después el switch reenvía los paquetes de manera que las computadoras conectadas a los puertos verdes estén separadas de las que están conectadas a los puertos rojos. Por ejemplo, los paquetes de difusión que se envíen por un puerto rojo no se recibirán en un puerto verde, tal como si hubiera dos redes LAN distintas. Al final del capítulo 4 veremos los detalles sobre las redes VLAN.

También existen otras topologías de LAN alámbrica. De hecho, la Ethernet conmutada es una versión moderna del diseño original de Ethernet en el que se difundían todos los paquetes a través de un solo cable lineal. Sólo una máquina podía transmitir con éxito en un instante dado, y se utilizaba un mecanismo de arbitraje distribuido para resolver los conflictos. Utilizaba un algoritmo simple: las computadoras podían transmitir siempre que el cable estuviera inactivo. Si ocurría una colisión entre dos o más paquetes, cada computadora esperaba un tiempo aleatorio y volvía a intentar. Llamaremos a esa versión **Ethernet clásica** por cuestión de claridad y, como tal vez se lo imagine, aprenderá sobre ella en el capítulo 4.

Las redes inalámbricas y las alámbricas se pueden dividir en diseños estáticos y dinámicos, dependiendo de la forma en que se asigna el canal. Una asignación estática típica sería dividir el tiempo en intervalos discretos y utilizar un algoritmo por turno rotatorio (*round-robin*), para que cada máquina pueda difundir los datos sólo cuando sea su turno de usar su intervalo. La asignación estática desperdicia la capacidad del canal cuando una máquina no tiene nada que decir durante su intervalo asignado, por lo que la mayoría de los sistemas tratan de asignar el canal en forma dinámica (es decir, bajo demanda).

Los métodos de asignación dinámica para un canal común pueden ser centralizados o descentralizados. En el método de asignación de canal centralizado hay una sola entidad (por ejemplo, la estación base en las redes celulares) que determina el turno de cada quien. Para ello podría aceptar varios paquetes y asignarles prioridades de acuerdo con algún algoritmo interno. En el método de asignación de canal descentralizado no hay una entidad central; cada máquina debe decidir por su cuenta si va a transmitir o no. Tal vez usted piense que esta metodología provoca un caos, pero no es así. Más adelante estudiaremos muchos algoritmos diseñados para poner orden a un potencial caos.

Vale la pena invertir un poco más de tiempo para hablar sobre las redes LAN en el hogar. En lo futuro es probable que todos los dispositivos en el hogar sean capaces de comunicarse con cualquier otro dispositivo, y todos ellos serán accesibles a través de Internet. Tal vez este acontecimiento sea uno de esos conceptos visionarios que nadie solicitó (como los controles remotos de TV o los teléfonos móviles), pero una vez que llegaron nadie se imagina cómo pudo haber vivido sin ellos.

Muchos dispositivos ya son capaces de conectarse en red. Entre ellos tenemos a las computadoras, los dispositivos de entretenimiento como las TV y los DVD, teléfonos y otros dispositivos electrónicos como las cámaras, aparatos como los radios relojes e infraestructura como los medidores de servicios y termostatos. Esta tendencia seguirá avanzando. Por ejemplo, es probable que el hogar promedio tenga una docena de relojes (es decir, en aparatos), los cuales, si estuvieran conectados a Internet, podrían ajustarse de manera automática al horario de verano para ahorrar energía solar. Es muy probable que el monitoreo remoto del hogar sea una aplicación muy popular en el futuro, ya que muchos hijos en edad adulta estarían dispuestos a invertir algo de dinero para ayudar a sus padres envejecidos a vivir con seguridad en sus propios hogares.

Aunque podríamos considerar a la red doméstica como cualquier otra LAN, es muy probable que tenga distintas propiedades. En primer lugar, los dispositivos en red tienen que ser muy fáciles de instalar. Los enrutadores inalámbricos son uno de los artículos que más devuelven los consumidores. Las personas compran uno porque desean una red inalámbrica en su hogar, pero al sacarlo de su caja descubren que no está “listo para usarse”; por lo tanto, prefieren devolverlo en lugar de esperar a ser atendidas en la línea telefónica de asistencia.

En segundo lugar, la red y los dispositivos tienen que operar en un modo a prueba de errores. Los aires acondicionados solían tener una perilla con cuatro posiciones: Apagado, bajo, medio y alto. Ahora tienen manuales de 30 páginas. Una vez que puedan conectarse en red, es probable que tan sólo el capítulo sobre seguridad sea de ese tamaño. Éste es un problema debido a que sólo los usuarios de computadoras están acostumbrados a lidiar con productos que no funcionan; el público que compra autos, televisores y refrigeradores es menos tolerante. Esperan productos que funcionen al 100% sin tener que contratar a un experto en computadoras.

En tercer lugar, el precio es imprescindible para el éxito. Las personas no pagarán una tarifa de \$50 dólares por un termostato con conexión a Internet debido a que pocas personas consideran que sea tan importante monitorear la temperatura de su hogar desde el trabajo. Aunque tal vez por \$5 dólares adicionales sí podría llegar a venderse.

En cuarto lugar, debe existir la posibilidad de empezar con uno o dos dispositivos para después expandir el alcance de la red en forma gradual. Esto significa que no debe haber guerras de formatos. Decir a los consumidores que compren periféricos con interfaces IEEE 1394 (*FireWire*) para luego retractarse unos cuantos años después y decir que USB 2.0 es la interfaz del mes, y luego cambiarla por la interfaz 802.11g (¡ups!, no, mejor que sea 802.11n), o quizá mejor 802.16 (distintas redes inalámbricas), son acciones que volverán a los consumidores muy escépticos. La interfaz de red tendrá que permanecer estable por décadas, así como los estándares de transmisión por televisión.

En quinto lugar, la seguridad y la confiabilidad serán de extrema importancia. Perder unos cuantos archivos debido a un virus de correo electrónico es una cosa; que un ladrón desarme nuestro sistema de seguridad desde su computadora móvil y después saquee nuestro hogar es muy distinto.

Una pregunta interesante es si las redes domésticas serán alámbricas o inalámbricas. La conveniencia y el costo favorecen a las redes inalámbricas, ya que no hay cables que instalar (o peor aún, reinstalar). La seguridad favorece a las redes alámbricas, ya que las ondas de radio que utilizan las redes inalámbricas pueden traspasar las paredes con facilidad. No todos se alegran al saber que los vecinos se están colgando de su conexión a Internet y leyendo su correo electrónico. En el capítulo 8 estudiaremos cómo se puede utilizar el cifrado para proveer seguridad, aunque es más fácil decirlo que hacerlo cuando los usuarios son inexpertos.

Una tercera opción que podría ser interesante es la de reutilizar las redes que ya se encuentren en el hogar. El candidato más obvio es la red formada por los cables eléctricos instalados por toda la casa. Las **redes por el cableado eléctrico** permiten difundir información por toda la casa a los dispositivos que se conectan a los tomacorrientes. De todas formas usted tiene que conectar la TV, y de esta forma puede obtener conectividad a Internet al mismo tiempo. La dificultad está en cómo llevar tanto electricidad como señales de datos al mismo tiempo. Parte de la respuesta es que estas señales utilizan distintas bandas de frecuencia.

En resumen, las redes LAN domésticas ofrecen muchas oportunidades y retos. La mayoría de estos retos se relacionan con la necesidad de que las redes sean fáciles de manejar, confiables y seguras (en especial en manos de los usuarios inexpertos), así como de bajo costo.

1.2.3 Redes de área metropolitana

Una **Red de Área Metropolitana**, o **MAN** (*Metropolitan Area Network*), cubre toda una ciudad. El ejemplo más popular de una MAN es el de las redes de televisión por cable disponibles en muchas ciudades. Estos sistemas surgieron a partir de los primeros sistemas de antenas comunitarias que se utilizaban en áreas donde la recepción de televisión por aire era mala. En esos primeros sistemas se colocaba una gran antena encima de una colina cercana y después se canalizaba una señal a las casas de los suscriptores.

Al principio estos sistemas se diseñaban con fines específicos en forma local. Después, las empresas empezaron a entrar al negocio y consiguieron contratos de los gobiernos locales para cablear ciudades completas. El siguiente paso fue la programación de televisión e incluso canales completos diseñados sólo para cable. A menudo estos canales eran altamente especializados, como canales de sólo noticias, sólo deportes, sólo cocina, sólo jardinería, etc. Pero desde su comienzo hasta finales de la década de 1990, estaban diseñados sólo para la recepción de televisión.

Cuando Internet empezó a atraer una audiencia masiva, los operadores de red de TV por cable empezaron a darse cuenta de que con unos cambios en el sistema, podían proveer servicio de Internet de dos vías en partes no usadas del espectro. En ese momento, el sistema de TV por cable empezó a transformarse, de ser una simple forma de distribuir televisión, para convertirse en una red de área metropolitana. A simple vista, una MAN podría tener la apariencia del sistema que se muestra en la figura 1-9. En esta figura podemos ver que se alimentan señales de televisión y de Internet en un amplificador de cabeceira para después distribuir las a los hogares de las personas. Volveremos a ver este tema con detalle en el capítulo 2.

Cabe mencionar que la televisión por cable no es la única MAN. Los recientes desarrollos en el acceso inalámbrico a Internet de alta velocidad han originado otra, la cual se estandarizó como IEEE 802.16 y se conoce comúnmente como **WiMAX**. Hablaremos sobre ella en el capítulo 4.

1.2.4 Redes de área amplia

Una **Red de Área Amplia**, o **WAN** (*Wide Area Network*), abarca una extensa área geográfica, por lo general un país o continente. Empezaremos nuestra discusión con las redes WAN alámbricas y usaremos el ejemplo de una empresa con sucursales en distintas ciudades.

La WAN en la figura 1-10 es una red que conecta las oficinas en Perth, Melbourne y Brisbane. Cada una de estas oficinas contiene computadoras destinadas a ejecutar programas de usuario (aplicaciones). Seguiremos el uso tradicional y llamaremos a estas máquinas **hosts**. Al resto de la red que conecta estos hosts se le denomina **subred de comunicación**, o para abreviar sólo **subred**. La tarea de la subred es transportar los mensajes de host a host, al igual que el sistema telefónico transporta las palabras (en realidad sólo los sonidos) de la persona que habla a la persona que escucha.




Figura 1-9. Una red de área metropolitana basada en la TV por cable.

En la mayoría de las redes WAN, la subred cuenta con dos componentes distintos: líneas de transmisión y elementos de conmutación. Las **líneas de transmisión** mueven bits entre máquinas. Se pueden fabricar a partir de alambre de cobre, fibra óptica o incluso enlaces de radio. Como la mayoría de las empresas no poseen líneas de transmisión, tienen que rentarlas a una compañía de telecomunicaciones. Los **elementos de conmutación** o **switches** son computadoras especializadas que conectan dos o más líneas de transmisión. Cuando los datos llegan por una línea entrante, el elemento de conmutación debe elegir una línea saliente hacia la cual reenviarlos. En el pasado, estas computadoras de conmutación han recibido varios nombres; ahora se conocen como **enrutador**.

Aprovechemos el momento para hablar un poco sobre el término “subred”. En un principio, su **único** significado era el de una colección de enrutadores y líneas de comunicación que transmitían paquetes desde el host de origen hasta el host de destino. Es necesario que nuestros lectores sepan que ha adquirido un segundo significado más reciente en conjunto con el direccionamiento de red. Hablaremos sobre este significado en el capítulo 5 y mientras nos apegaremos al significado original (una colección de líneas y enrutadores).

Según nuestra descripción de la WAN, ésta es muy parecida a una LAN alámbrica extensa, sólo que hay ciertas diferencias importantes que van más allá de los cables extensos. Por lo general, en una WAN los hosts y la subred pertenecen a distintas personas, quienes actúan también como operadores. En nuestro ejemplo, los empleados podrían ser responsables de sus propias computadoras mientras que el departamento de TI de la empresa está a cargo del resto de la red. En los siguientes ejemplos veremos límites más claros, en donde el proveedor de red o compañía telefónica opera la subred. Al separar los aspectos exclusivos de comunicación (la subred) de los aspectos relacionados con la aplicación (los hosts) se simplifica en forma considerable el diseño de la red en general.

Una segunda diferencia es que los enrutadores por lo general conectan distintos tipos de tecnología de red. Por ejemplo, las redes dentro de las oficinas pueden usar la tecnología de Ethernet conmutada mientras que las líneas de transmisión de larga distancia pueden ser enlaces SONET (que veremos en el capítulo 2). Se requiere algún dispositivo para conectarlas. El lector inteligente observará que esto va más allá de nuestra definición de una red. Esto significa que muchas redes WAN serán de hecho **interredes**, o redes compuestas formadas por más de una red. En la siguiente sección veremos más detalles sobre las interredes.




Figura 1-10. Una WAN que conecta tres sucursales en Australia.

Una última diferencia está en lo que se conecta a la subred. Podrían ser computadoras individuales, como en el caso de la conexión a redes LAN, o podrían ser redes LAN completas. Ésta es la forma en que se construyen redes más grandes a partir de otras más pequeñas. En lo que concierne a la subred, ésta hace el mismo trabajo.

Ahora estamos en posición de ver otras dos variedades de redes WAN. En primer lugar, en vez de rentar líneas de transmisión dedicadas, una empresa podría conectar sus oficinas a Internet. Esto le permite hacer conexiones entre las oficinas como enlaces virtuales que utilizan la capacidad subyacente de Internet. A este arreglo, que se muestra en la figura 1-11, se le denomina **VPN (Red Privada Virtual)**, del inglés *Virtual Private Network*). Si se le compara con un arreglo dedicado, una VPN tiene la ventaja común de la virtualización, lo cual significa que provee flexibilidad en la reutilización de un recurso (conectividad a Internet). Para ver esto, considere lo fácil que sería conectar una cuarta oficina. Una VPN también tiene la desventaja común de la virtualización, lo cual significa que carece de control sobre los recursos subyacentes. Con una línea dedicada, la capacidad está clara. Con una VPN la capacidad puede variar según el servicio de Internet contratado.

La segunda variación es que una empresa distinta puede operar la subred. Al operador de la subred se le conoce como **proveedor de servicios de red** y las oficinas son sus clientes. En la figura 1-12 se muestra esta estructura. El operador de la subred se conecta también con otros clientes, siempre y cuando puedan pagar y les pueda proveer servicio. Como sería un servicio de red decepcionante si los clientes sólo pudieran enviarse paquetes entre sí, el operador de la subred también puede conectarse con otras redes que formen parte de Internet. A dicho operador de subred se le conoce como **ISP (Proveedor de Servicios de Internet)**, del inglés *Internet Service Provider*) y la subred es una **red ISP**. Los clientes que se conectan al ISP reciben servicio de Internet.

Podemos usar la red ISP para ver por adelantado algunas cuestiones clave que estudiaremos en los capítulos posteriores. En la mayoría de las redes WAN, la red contiene muchas líneas de transmisión, cada una de las cuales conecta a un par de enrutadores. Si dos enrutadores que no comparten una línea de




Figura 1-11. Una WAN que utiliza una red privada virtual.

transmisión desean comunicarse, deben hacerlo en forma indirecta a través de otros enrutadores. Puede haber muchas rutas en la red que conecten a estos dos enrutadores. Al proceso por el cual la red decide qué ruta tomar se le conoce como **algoritmo de enrutamiento**. Existen muchos algoritmos de este tipo. La manera en que cada enrutador toma la decisión de hacia dónde debe enviar el siguiente paquete se le denomina **algoritmo de reenvío**. También existen muchos de éstos. En el capítulo 5 estudiaremos ambos tipos de algoritmos con detalle.

Otros tipos de redes WAN utilizan mucho las tecnologías inalámbricas. En los sistemas de satélite, cada computadora en la Tierra tiene una antena a través de la cual es posible enviar y recibir datos de un satélite en órbita. Todas las computadoras pueden escuchar la salida *proveniente* del satélite y, en algunos casos, también pueden escuchar las transmisiones que envían sus computadoras vecinas *hacia* el satélite. Las redes de satélite son de difusión por naturaleza y son más útiles cuando es importante contar con la propiedad de difusión.

La red de telefonía celular es otro ejemplo de una WAN que utiliza tecnología inalámbrica. Este sistema ya pasó por tres generaciones y hay una cuarta por venir. La primera generación fue analógica y sólo para voz. La segunda fue digital y sólo para voz. La tercera generación es digital y se pueden transmitir tanto datos como voz. Cada estación base en un sistema celular cubre una distancia mucho mayor que una LAN inalámbrica, en donde el rango se mide en kilómetros en vez de decenas de metros. Las estaciones base se conectan entre sí mediante una red troncal que por lo general es alámbrica. Las velocidades de datos de las redes celulares se encuentran comúnmente en el orden de 1 Mbps, un valor mucho menor al de una LAN inalámbrica que puede estar en el orden de hasta 100 Mbps. En el capítulo 2 veremos muchos detalles sobre estas redes.

1.2.5 Interredes

Existen muchas redes en el mundo, a menudo con distintos componentes de hardware y software. Por lo general, las personas conectadas a una red se quieren comunicar con las personas conectadas a una red




Figura 1-12. Una WAN que utiliza una red de ISP.

distinta; para lograrlo, es necesario conectar redes distintas que con frecuencia son incompatibles. A una colección de redes interconectadas se le conoce como **interred** o **internet**. Utilizaremos estos términos en un sentido genérico, en contraste a la red Internet mundial (que es una internet específica), a la cual nos referiremos siempre con I mayúscula. Internet usa redes de ISP para conectar redes empresariales, domésticas y muchos otros tipos más. Analizaremos la red Internet detalladamente más adelante.

A menudo se confunden las subredes, las redes y las interredes. El término “subred” tiene más sentido en el contexto de una red de área amplia, en donde se refiere a la colección de enrutadores y líneas de comunicación que pertenecen al operador de red. Como analogía, el sistema telefónico está compuesto por oficinas de conmutación telefónica conectadas entre sí mediante líneas de alta velocidad y conectadas a los hogares y negocios mediante líneas de baja velocidad. Estas líneas y equipos, que pertenecen y son administradas por la compañía telefónica, forman la subred del sistema telefónico. Los teléfonos en sí (los hosts en esta analogía) no forman parte de la subred.

Una red se forma al combinar una subred y sus hosts. Sin embargo, la palabra “red” a menudo también se utiliza en un sentido amplio. Podríamos describir una subred como una red, como en el caso de la “red ISP” de la figura 1-12. También podríamos describir una interred como una red, como en el caso de la WAN en la figura 1-10. Continuaremos con una práctica similar y cuando haya que diferenciar una red de otras distribuciones, nos apegaremos a nuestra definición original de una colección de computadoras interconectadas mediante una sola tecnología.

Ahora veamos detalladamente cómo está constituida una interred. Sabemos que una interred se forma cuando hay distintas redes interconectadas. A nuestro parecer, conectar una LAN y una WAN o conectar dos redes LAN es la forma usual de formar una interred, pero la industria no ha llegado a un buen acuerdo en cuanto a la terminología utilizada en esta área. Hay dos reglas prácticas y útiles a este respecto. En primer lugar, si varias organizaciones han pagado para construir distintas partes de la red y cada una se encarga de dar mantenimiento a la parte que le corresponde, entonces tenemos una interred en vez de una sola red. En segundo lugar, si la tecnología subyacente es distinta en diferentes partes (por ejemplo, difusión frente punto a punto y alámbrica frente a inalámbrica), es probable que sea una interred.

Para profundizar en este tema, hablaremos sobre la forma en que se pueden conectar dos redes distintas. El nombre general para una máquina que realiza una conexión entre dos o más redes y provee la traducción necesaria, tanto en términos de hardware como de software, es **puerta de enlace** (*gateway*). Las puertas de enlace se distinguen por la capa en la que operan en la jerarquía de protocolos. En la siguiente sección hablaremos mucho más sobre las capas y las jerarquías de protocolos, pero por ahora basta con imaginar que las capas superiores están más relacionadas con las aplicaciones (como la web), mientras que las capas inferiores están más relacionadas con los enlaces de transmisión (como Ethernet).

Como el beneficio de formar una internet es para conectar computadoras entre distintas redes, no es conveniente usar una puerta de enlace de una capa demasiado baja, ya que no podremos realizar conexiones entre distintos tipos de redes. Tampoco es conveniente usar una puerta de enlace de una capa demasiado alta, o de lo contrario la conexión sólo funcionará para ciertas aplicaciones. A la capa en la parte media que resulta ser la “ideal” se le denomina comúnmente **capa de red**; un enrutador es una puerta de enlace que conmuta paquetes en la capa de red. Así, para detectar una interred o internet hay que buscar una red que tenga enrutadores.

1.3 SOFTWARE DE RED

Las primeras redes de computadoras se diseñaron teniendo en cuenta al hardware como punto principal y al software como secundario. Pero esta estrategia ya no funciona. Ahora el software de red está muy estructurado. En las siguientes secciones examinaremos con cierto detalle la técnica para estructurar el software. La metodología aquí descrita constituye la piedra angular de todo el libro y, por lo tanto, se repetirá en secciones posteriores.

1.3.1 Jerarquías de protocolos

Para reducir la complejidad de su diseño, la mayoría de las redes se organizan como una pila de **capas** o **niveles**, cada una construida a partir de la que está abajo. El número de capas, su nombre, el contenido de cada una y su función difieren de una red a otra. El propósito de cada capa es ofrecer ciertos servicios a las capas superiores, mientras les oculta los detalles relacionados con la forma en que se implementan los servicios ofrecidos. Es decir, cada capa es un tipo de máquina virtual que ofrece ciertos servicios a la capa que está encima de ella.

En realidad este concepto es familiar y se utiliza en muchas áreas de las ciencias computacionales, en donde se le conoce de muchas formas: ocultamiento de información, tipos de datos abstractos, encapsulamiento de datos y programación orientada a objetos. La idea fundamental es que una pieza particular de software (o hardware) provee un servicio a sus usuarios pero mantiene ocultos los detalles de su estado interno y los algoritmos que utiliza.

Cuando la capa n en una máquina lleva a cabo una conversación con la capa n en otra máquina, a las reglas y convenciones utilizadas en esta conversación se les conoce como el protocolo de la capa n . En esencia, un **protocolo** es un acuerdo entre las partes que se comunican para establecer la forma en que se llevará a cabo esa comunicación. Como analogía, cuando a un hombre le presentan una mujer, ella puede elegir si extiende su mano o no. Él a su vez, puede decidir entre estrechar la mano o besarla, dependiendo por ejemplo de si ella es una abogada estadounidense en una reunión de negocios, o una princesa europea en un baile formal. Si se viola el protocolo se hará más difícil la comunicación, si no es que se vuelve imposible.

En la figura 1-13 se ilustra una red de cinco capas. Las entidades que conforman las correspondientes capas en diferentes máquinas se llaman **iguales** (*peers*). Los iguales pueden ser procesos de software,




Figura 1-13. Capas, protocolos e interfaces.

dispositivos de hardware o incluso seres humanos. En otras palabras, los iguales son los que se comunican a través del protocolo.

En realidad no se transfieren datos de manera directa desde la capa n de una máquina a la capa n de otra máquina, sino que cada capa pasa los datos y la información de control a la capa inmediatamente inferior, hasta que se alcanza a la capa más baja. Debajo de la capa 1 se encuentra el **medio físico** a través del cual ocurre la comunicación real. En la figura 1-13 se muestra la comunicación virtual con líneas punteadas y la comunicación física con líneas sólidas.

Entre cada par de capas adyacentes hay una **interfaz**. Ésta define las operaciones y servicios primitivos que pone la capa más baja a disposición de la capa superior inmediata. Cuando los diseñadores de redes deciden cuántas capas incluir en una red y qué debe hacer cada una, la consideración más importante es definir interfaces limpias entre las capas. Al hacer esto es necesario que la capa desempeñe un conjunto específico de funciones bien entendidas. Además de minimizar la cantidad de información que se debe pasar entre las capas, las interfaces bien definidas también simplifican el reemplazo de una capa con un protocolo o implementación totalmente diferente (por ejemplo, reemplazar todas las líneas telefónicas por canales de satélite), ya que todo lo que se requiere del nuevo protocolo o implementación es que ofrezca exactamente el mismo conjunto de servicios a su vecino de arriba, como lo hacía el protocolo o la implementación anterior. Es común que distintos hosts utilicen diferentes implementaciones del mismo protocolo (a menudo escrito por otras compañías). De hecho, el protocolo en sí puede cambiar en cierta capa sin que las capas superior e inferior lo noten.

A un conjunto de capas y protocolos se le conoce como **arquitectura de red**. La especificación de una arquitectura debe contener suficiente información como para permitir que un programador escriba el programa o construya el hardware para cada capa, de manera que se cumpla correctamente el protocolo apropiado. Ni los detalles de la implementación ni la especificación de las interfaces forman parte de la arquitectura, ya que están ocultas dentro de las máquinas y no se pueden ver desde el exterior. Ni siquiera es necesario que las interfaces en todas las máquinas de una red sean iguales, siempre y cuando cada máquina pueda utilizar todos los protocolos correctamente. La lista de los protocolos utilizados por cierto

sistema, un protocolo por capa, se le conoce como **pila de protocolos**. Las arquitecturas de red, las pilas de protocolos y los protocolos mismos son los temas principales de este libro.

Una analogía podría ayudar a explicar la idea de la comunicación entre múltiples capas. Imagine a dos filósofos (procesos de iguales en la capa 3), uno de los cuales habla urdú e inglés, mientras que el otro habla chino y francés. Como no tienen un lenguaje común, cada uno contrata a un traductor (procesos de iguales en la capa 2) y cada uno de los traductores a su vez contacta a una secretaria (procesos de iguales en la capa 1). El filósofo 1 desea comunicar su afición por el *oryctolagus cuniculus* a su igual. Para ello pasa un mensaje (en español) a través de la interfaz de las capas 2-3 a su traductor para decirle: “Me gustan los conejos”, como se muestra en la figura 1-14. Los traductores han acordado un idioma neutral conocido por ambos, el holandés, así el mensaje es convertido a “*Ik vind konijnen leuk*”. La elección del idioma es el protocolo de la capa 2 y depende de los procesos de iguales de dicha capa.

Después, el traductor pasa el mensaje a una secretaria para que lo transmita, por ejemplo, mediante correo electrónico (el protocolo de la capa 1). Cuando el mensaje llega a la otra secretaria, ésta lo pasa al traductor local, quien lo traduce al francés y lo pasa a través de la interfaz de las capas 2-3 al segundo filósofo 2. Observe que cada protocolo es totalmente independiente de los demás siempre y cuando no cambien las interfaces. Por ejemplo, los traductores pueden cambiar de holandés al finlandés siempre y cuando ambos estén de acuerdo y ninguno cambie su interfaz con las capas 1 o 3. De manera similar, las secretarías pueden cambiar del correo electrónico al teléfono sin molestar (o incluso informar) a las demás capas. Cada proceso puede agregar algo de información destinada sólo a su igual. Esta información no se pasa a la capa superior.




Figura 1-14. La arquitectura filósofo-traductor-secretaria.

Ahora considere un ejemplo más técnico: cómo proveer comunicación a la capa superior de la red de cinco capas de la figura 1-15. Un proceso de aplicación que se ejecuta en la capa 5 produce un mensaje, M , y lo pasa a la capa 4 para que lo transmita. La capa 4 coloca un **encabezado** al frente del mensaje para identificarlo y pasa el resultado a la capa 3. El encabezado incluye información de control, como direcciones, para permitir que la capa 4 en la máquina de destino entregue el mensaje. Otros ejemplos de la información de control que se utiliza en algunas capas son los números de secuencia (en caso de que la capa inferior no preserve el orden del mensaje), los tamaños y los tiempos.

En muchas redes no se impone un límite en cuanto al tamaño de los mensajes que se transmiten en el protocolo de la capa 4, pero casi siempre hay un límite impuesto por el protocolo de la capa 3. En consecuencia, la capa 3 debe descomponer los mensajes entrantes en unidades más pequeñas llamadas paquetes, y colocar un encabezado al frente de cada paquete. En este ejemplo, M se divide en dos partes: M_1 y M_2 , los cuales se transmitirán por separado.

La capa 3 decide cuál de las líneas salientes usar y pasa los paquetes a la capa 2; esta última agrega a cada pieza no sólo un encabezado, sino también un terminador, y pasa la unidad restante a la capa 1 para su transmisión física. En la máquina receptora el mensaje pasa hacia arriba, de capa en capa, y los encabezados se van eliminando a medida que progresa. Ninguno de los encabezados para las capas inferiores a n se pasa a la capa n .

Lo importante a entender sobre la figura 1-15 es la relación entre la comunicación virtual y real, además de la diferencia entre los protocolos y las interfaces. Por ejemplo, los procesos de iguales en la capa 4 piensan conceptualmente en su comunicación como si fuera “horizontal” y utilizan el protocolo de la capa 4. Es probable que cada uno tenga procedimientos llamados *EnviarAlOtroLado* y *RecibirDelOtroLado*, aun cuando en realidad estos procedimientos se comunican con las capas inferiores a través de la interfaz de las capas 3-4, no con el otro lado.

La abstracción de los procesos de iguales es imprescindible para todo diseño de red. Al usarla, la inmanejable tarea de diseñar toda la red se puede fragmentar en varios problemas de diseño más pequeños y manejables, es decir, el diseño de las capas individuales.




Figura 1-15. Ejemplo de flujo de información que soporta la comunicación virtual en la capa 5.

Aunque la sección 1.3 se llama “Software de red”, vale la pena mencionar que las capas inferiores de una jerarquía de protocolos se implementan con frecuencia en el hardware o firmware. Sin embargo, están implicados los algoritmos de protocolos complejos, incluso aunque estén integrados (en todo o en parte) al hardware.

1.3.2 Aspectos de diseño para las capas

Algunos de los aspectos clave de diseño que ocurren en las redes de computadoras están presentes en las diversas capas. A continuación mencionaremos brevemente los más importantes.

La confiabilidad es el aspecto de diseño enfocado en verificar que una red opere correctamente, aun cuando esté formada por una colección de componentes que sean, por sí mismos, poco confiables. Piense en los bits de un paquete que viajan a través de la red. Existe la posibilidad de que algunas de estas piezas se reciban dañadas (invertidas) debido al ruido eléctrico, a las señales aleatorias inalámbricas, a fallas en el hardware, a errores del software, etc. ¿Cómo es posible detectar y corregir estos errores?

Un mecanismo para detectar errores en la información recibida utiliza códigos de **detección de errores**. Así, la información que se recibe de manera incorrecta puede retransmitirse hasta que se reciba de manera correcta. Los códigos más poderosos cuentan con **corrección de errores**, en donde el mensaje correcto se recupera a partir de los bits posiblemente incorrectos que se recibieron originalmente. Ambos mecanismos funcionan añadiendo información redundante. Se utilizan en capas bajas para proteger los paquetes que se envían a través de enlaces individuales, y en capas altas para verificar que el contenido correcto fue recibido.

Otro aspecto de la confiabilidad consiste en encontrar una ruta funcional a través de una red. A menudo hay múltiples rutas entre origen y destino, y en una red extensa puede haber algunos enlaces o enrutadores descompuestos. Suponga que la red está caída en Alemania. Los paquetes que se envían de Londres a Roma a través de Alemania no podrán pasar, pero para evitar esto, podríamos enviar los paquetes de Londres a Roma vía París. La red debería tomar esta decisión de manera automática. A este tema se le conoce como **enrutamiento**.

Un segundo aspecto de diseño se refiere a la evolución de la red. Con el tiempo, las redes aumentan su tamaño y emergen nuevos diseños que necesitan conectarse a la red existente. Recientemente vimos el mecanismo de estructuración clave que se utiliza para soportar el cambio dividiendo el problema general y ocultando los detalles de la implementación: **distribución de protocolos en capas**. También existen muchas otras estrategias.

Como hay muchas computadoras en la red, cada capa necesita un mecanismo para identificar los emisores y receptores involucrados en un mensaje específico. Este mecanismo se conoce como **direccionamiento** o **nombramiento** en las capas altas y bajas, respectivamente.

Un aspecto del crecimiento es que las distintas tecnologías de red a menudo tienen diferentes limitaciones. Por ejemplo, no todos los canales de comunicación preservan el orden de los mensajes que se envían en ellos, por lo cual es necesario idear soluciones para enumerar los mensajes. Otro ejemplo es el de las diferencias en el tamaño máximo de un mensaje que las redes pueden transmitir. Esto provoca la creación de mecanismos para desensamblar, transmitir y después volver a ensamblar los mensajes. A este tema en general se le conoce como **interconexión de redes** (*internetworking*).

Cuando las redes crecen, surgen nuevos problemas. Las ciudades pueden tener problemas de tráfico, escasez de números telefónicos y es fácil perderse. No muchas personas tienen estos problemas en su propio vecindario, pero en toda la ciudad pueden representar un gran problema. Se dice que los diseños que siguen funcionando bien cuando la red aumenta su tamaño son **escalables**.

Un tercer aspecto de diseño radica en la asignación de recursos. Las redes proveen un servicio a los hosts desde sus recursos subyacentes, como la capacidad de las líneas de transmisión. Para hacer bien su

trabajo necesitan mecanismos que dividan sus recursos de manera que un host no interfiera demasiado con otro host.

Muchos diseños comparten el ancho de banda de una red en forma dinámica, de acuerdo con las necesidades a corto plazo de los hosts, en vez de otorgar a cada host una fracción fija del ancho de banda que puede llegar a utilizar o quizás no. A este diseño se le denomina **multiplexado estadístico**, lo cual significa que se comparten los recursos con base en la demanda. Se puede aplicar en capas bajas para un solo enlace o en capas altas para una red, o incluso para aplicaciones que utilizan la red.

Un problema de asignación que ocurre en todas las capas es cómo evitar que un emisor rápido inunde de datos a un receptor lento. Con frecuencia se utiliza retroalimentación del receptor al emisor. A este tema se le denomina **control de flujo**. Algunas veces el problema es que la red sufre un exceso de solicitudes debido a que hay demasiadas computadoras que desean enviar una gran cantidad de información y la red no lo puede entregar todo. A esta sobrecarga de la red se le conoce como **congestión**. Una estrategia es que cada computadora reduzca su demanda cuando experimenta congestión. Esto también se puede usar en todas las capas.

Es interesante observar que la red puede ofrecer más recursos que simplemente el ancho de banda. Para usos como transmitir video en vivo, la puntualidad de la entrega es en extremo importante. La mayoría de las redes deben proveer servicio a las aplicaciones que desean esta entrega en **tiempo real** al mismo tiempo que proveen servicio a las aplicaciones que desean un alto rendimiento. La **calidad del servicio** es el nombre que se da a los mecanismos que reconcilian estas demandas competitivas.

El último aspecto de diseño importante es asegurar la red y defenderla contra distintos tipos de amenazas. Una de las amenazas que mencionamos antes es la de espiar las comunicaciones. Los mecanismos que proveen **confidencialidad** nos defienden contra esta amenaza y se utilizan en múltiples capas. Los mecanismos de **autenticación** evitan que alguien se haga pasar por otra persona. Se pueden usar para diferenciar los sitios web bancarios falsos de los verdaderos, o para permitir que la red celular verifique que una llamada realmente provenga de nuestro teléfono para pagar la cuenta. Otros mecanismos para la **integridad** evitan cambios clandestinos a los mensajes, como cuando se altera el mensaje “cargar \$10 a mi cuenta” para convertirlo en “cargar \$1000 dólares a mi cuenta”. Todos estos diseños se basan en la criptografía que estudiaremos en el capítulo 8.

1.3.3 Comparación entre servicio orientado a conexión y servicio sin conexión

Las capas pueden ofrecer dos tipos distintos de servicio a las capas superiores: orientado a conexión y sin conexión. En esta sección analizaremos estos dos tipos y examinaremos las diferencias entre ellos.

El servicio **orientado a conexión** está modelado a partir del sistema telefónico. Para hablar con alguien levantamos el auricular, marcamos el número, hablamos y después colgamos. De manera similar, para usar un servicio de red orientado a conexión, el usuario del servicio establece primero una conexión, la utiliza y después la libera. El aspecto esencial de una conexión es que funciona como un tubo: el emisor mete objetos (bits) en un extremo y el receptor los toma en el otro extremo. En la mayoría de los casos se conserva el orden de manera que los bits llegan en el orden en el que se enviaron.

En algunos casos al establecer una conexión, el emisor, el receptor y la subred llevan a cabo una **negociación** en cuanto a los parámetros que se van a usar, como el tamaño máximo del mensaje, la calidad requerida del servicio y demás cuestiones relacionadas. Por lo general, uno de los lados hace una propuesta y el otro puede aceptarla, rechazarla o elaborar una contrapropuesta. Un circuito es otro nombre para una conexión con recursos asociados, como un ancho de banda fijo. Esto se remonta a la red telefónica, en la cual un circuito era una ruta sobre alambre que transmitía una conversación telefónica.

En contraste al servicio orientado a la conexión, el servicio **sin conexión** está modelado a partir del sistema postal. Cada mensaje (carta) lleva la dirección de destino completa, y cada uno es enrutado hacia

los nodos intermedios dentro del sistema, en forma independiente a todos los mensajes subsecuentes. Hay distintos nombres para los mensajes en diferentes contextos: un **paquete** es un mensaje en la capa de red. Cuando los nodos intermedios reciben un mensaje completo antes de enviarlo al siguiente nodo, se le llama **conmutación de almacenamiento y envío**. La alternativa en donde la transmisión subsiguiente de un mensaje en un nodo empieza antes de que éste la reciba por completo, se conoce como “conmutación al vuelo”. Por lo general, cuando se envían dos mensajes al mismo destino, el primero que se envíe será el primero en llegar. Sin embargo, es posible que el primero que se envíe se retrase de manera que el segundo llegue primero.

Cada tipo de servicio se puede caracterizar con base en su confiabilidad. Algunos servicios son confiables en cuanto a que nunca pierden datos. Por lo general, para implementar un servicio confiable, el receptor tiene que confirmar la recepción de cada mensaje, de manera que el emisor esté seguro de que hayan llegado. El proceso de confirmación de recepción introduce sobrecarga y retardos, que a menudo valen la pena pero algunas veces no son deseables.

Una situación común en la que es apropiado un servicio confiable orientado a la conexión es la transferencia de archivos. El propietario del archivo desea estar seguro de que todos los bits lleguen correctamente y en el mismo orden en el que se enviaron. Muy pocos clientes que transfieren archivos preferirían un servicio que ocasionalmente revuelva o pierda unos cuantos bits, incluso aunque fuera mucho más rápido.

El servicio confiable orientado a la conexión tiene dos variaciones menores: secuencias de mensajes y flujos de bytes. En la primera variante se conservan los límites de los mensajes. Cuando se envían dos mensajes de 1024 bytes, llegan como dos mensajes distintos de 1024 bytes y nunca como un mensaje de 2048 bytes. En la segunda variante, la conexión es simplemente un flujo de bytes sin límites en los mensajes. Cuando llegan 2048 bytes al receptor, no hay manera de saber si se enviaron como un mensaje de 2048 bytes, como dos mensajes de 1024 bytes o como 2048 mensajes de 1 byte. Si se envían las páginas de un libro a través de una red a una máquina de fotocomposición en forma de mensajes separados, probablemente sea importante preservar los límites de los mensajes. Por otro lado, para descargar una película en DVD, todo lo que se necesita es un flujo de bytes del servidor a la computadora del usuario. Los límites de los mensajes dentro de la película no son relevantes.

En algunas aplicaciones, los retardos de tránsito ocasionados por las confirmaciones de recepción son inaceptables. Una de estas aplicaciones es el tráfico de voz digitalizada o **voz sobre IP**. Es preferible para los usuarios del teléfono escuchar un poco de ruido en la línea de vez en cuando que experimentar un retardo al esperar las confirmaciones de recepción. De manera similar, al transmitir una conferencia de video no hay problema si unos cuantos píxeles están mal, pero es molesto cuando la imagen se sacude mientras el flujo se detiene y avanza para corregir errores.

No todas las aplicaciones requieren conexiones. Por ejemplo, los emisores de correo electrónico basura (*spammers*) envían su correo a muchos destinatarios. Es probable que el emisor no quiera tener que pasar por el problema de establecer y dismantelar una conexión con un destinatario sólo para enviarle un mensaje. Tampoco es esencial una entrega cien por ciento confiable, sobre todo si eso es más costoso. Todo lo que se requiere es una forma de enviar un solo mensaje que tenga una muy alta probabilidad de llegar, aunque sin garantías. Al servicio sin conexión no confiable (que significa sin confirmación de recepción) se le denomina servicio de **datagramas**, en analogía al servicio de telegramas que tampoco devuelve una confirmación de recepción al emisor. A pesar de ser poco confiable, es la forma más dominante en la mayoría de las redes por motivos que veremos más adelante.

En otros casos es conveniente no tener que establecer una conexión para enviar un mensaje, pero la confiabilidad es esencial. En estas aplicaciones se puede utilizar el servicio de **datagramas con confirmación de recepción**. Es como enviar una carta certificada y solicitar una confirmación de recepción. Al regresar la confirmación de recepción el emisor tiene la absoluta certeza de que la carta se entregó al destinatario correcto y que no se perdió en el camino. La mensajería de texto en los teléfonos móviles es un ejemplo.

Hay otro servicio conocido como servicio de **solicitud-respuesta**. En este servicio el emisor transmite un solo datagrama que contiene una solicitud; al receptor envía la respuesta. El servicio de solicitud-respuesta se utiliza mucho para implementar la comunicación en el modelo cliente-servidor; el cliente emite una petición y el servidor le responde. Por ejemplo, el cliente de un teléfono móvil podría enviar una consulta a un servidor de mapas para recuperar los datos del mapa de la ubicación actual. En la figura 1-16 se sintetizan los tipos de servicios antes descritos.

Orientado a conexión	Servicio	Ejemplo
	Flujo de mensajes confiable.	Secuencia de páginas.
	Flujo de bytes confiable.	Descarga de películas.
Sin conexión	Conexión no confiable.	Voz sobre IP.
	Datagrama no confiable.	Correo electrónico basura.
	Datagrama confirmación de recepción.	Mensajería de texto.
	Solicitud-respuesta.	Consulta en una base de datos.

Figura 1-16. Seis tipos distintos de servicios.

Tal vez el concepto de usar una comunicación poco confiable le parezca confuso en un principio. Después de todo, ¿por qué preferiría alguien una comunicación poco confiable en vez de una comunicación confiable? Primero que nada, tal vez la comunicación confiable (en nuestro contexto significa que es con confirmación de recepción) no esté disponible en cierta capa. Por ejemplo, Ethernet no provee una comunicación confiable. Los paquetes se pueden dañar ocasionalmente durante el tránsito. Las capas de protocolos más altas deben tener la capacidad de recuperarse de este problema. En particular, muchos servicios confiables se basan en un servicio de datagramas no confiables. En segundo lugar, los retardos inherentes al proveer un servicio confiable tal vez sean inaceptables, en especial en las aplicaciones de tiempo real como multimedia. Éstas son las razones por las que coexisten la comunicación confiable y la comunicación poco confiable.

1.3.4 Primitivas de servicios

Un servicio se puede especificar de manera formal como un conjunto de **primitivas** (operaciones) disponibles a los procesos de usuario para que accedan al servicio. Estas primitivas le indican al servicio que desarrollen alguna acción o que informen sobre la acción que haya tomado una entidad par. Si la pila de protocolos se encuentra en el sistema operativo, como se da en la mayoría de los casos, por lo general las primitivas son llamadas al sistema. Estas llamadas provocan un salto al modo de kernel, que a su vez devuelve el control de la máquina al sistema operativo para que envíe los paquetes necesarios.

El conjunto de primitivas disponibles depende de la naturaleza del servicio que se va a ofrecer. Las primitivas para el servicio orientado a conexión son distintas de las primitivas para el servicio sin conexión. Como un ejemplo mínimo de las primitivas de servicio que se podrían ofrecer para implementar un flujo de bytes confiable, considere las primitivas que se enlistan en la figura 1-17. Estas primitivas serán familiares para los fanáticos de la interfaz de sockets de Berkeley, ya que son una versión simplificada de esa interfaz.

Primitiva	Significado
LISTEN	Bloquea en espera de una conexión entrante.
CONNECT	Establece una conexión con un igual en espera.
ACCEPT	Acepta una conexión entrante de un igual.
RECEIVE	Bloquea en espera de un mensaje entrante.
SEND	Envía un mensaje al igual.
DISCONNECT	Termina una conexión.

Figura 1-17. Seis primitivas de servicios que proveen un servicio simple orientado a conexión.

Podríamos usar estas primitivas para una interacción petición-respuesta en un entorno cliente-servidor. Para ilustrar esto, vamos a esbozar un protocolo simple que implementa el servicio mediante datagramas con confirmación de recepción.

Primero, el servidor ejecuta LISTEN para indicar que está preparado para aceptar conexiones entrantes. Una forma común de implementar LISTEN es mediante una llamada de bloqueo del sistema. Después de ejecutar la primitiva, el proceso servidor se bloquea hasta que aparezca una petición de conexión.

Después, el proceso cliente ejecuta CONNECT para establecer una conexión con el servidor. La llamada a CONNECT necesita especificar con quién se va a realizar la conexión, por lo que podría incluir un parámetro para proporcionar la dirección del servidor. A continuación, lo más común es que el sistema operativo envíe un paquete al igual para pedirle que se conecte, como se muestra en la sección (1) de la figura 1-18. El proceso cliente se suspende hasta que haya una respuesta.

Cuando el paquete llega al servidor, el sistema operativo ve que el paquete solicita una conexión. Verifica que haya alguien escuchando y, en ese caso, desbloquea al que está escuchando. Ahora el proceso servidor puede establecer la conexión con la llamada a ACCEPT. Esta llamada envía una respuesta (2) de vuelta al proceso cliente para aceptar la conexión. Al llegar esta respuesta se libera el cliente. En este punto, el cliente y el servidor se están ejecutando y tienen una conexión establecida.

La analogía obvia entre este protocolo y la vida real es un cliente que llama al gerente de servicio al cliente de una empresa. Al empezar el día, el gerente de servicio se sienta a un lado de su teléfono en caso de que suene. Después, un cliente hace una llamada. Cuando el gerente levanta el teléfono se establece la conexión.

El siguiente paso es que el servidor ejecute RECEIVE y se prepare para aceptar la primera petición. Por lo general, el servidor hace esto justo después de ser liberado de la primitiva LISTEN, antes de que la confirmación de recepción pueda regresar al cliente. La llamada a RECEIVE bloquea al servidor.




Figura 1-18. Una interacción cliente-servidor simple mediante el uso de datagramas con confirmación de recepción.

Entonces, el cliente ejecuta SEND para transmitir su petición (3) después de ejecutar RECEIVE para obtener la respuesta. La llegada del paquete solicitado a la máquina servidor desbloquea el servidor, de manera que pueda manejar la petición. Después de realizar su trabajo, el servidor usa SEND para devolver la respuesta al cliente (4). Al llegar este paquete se desbloquea el cliente, que ahora puede inspeccionar la respuesta. Si el cliente tiene peticiones adicionales, puede hacerlas ahora.

Cuando el cliente termina, ejecuta DISCONNECT para terminar la conexión (5). Por lo general una primitiva DISCONNECT inicial es una llamada de bloqueo, la cual suspende al cliente y envía un paquete al servidor para indicar que ya no necesita la conexión. Cuando el servidor recibe el paquete también emite una primitiva DISCONNECT por su cuenta, envía una confirmación de recepción al cliente y libera la conexión (6). Cuando el paquete del servidor regresa a la máquina cliente, se libera el proceso cliente y se interrumpe la conexión. En esencia, así es como funciona la comunicación orientada a conexión.

Por desgracia la vida no es tan simple. Aquí pueden salir mal muchas cosas. La sincronización puede estar mal (por ejemplo, que termine CONNECT antes de LISTEN), se pueden perder paquetes, etc. Más adelante analizaremos con mayor detalle estas cuestiones, pero por el momento en la figura 1-18 se resume la forma en que podría trabajar la comunicación cliente-servidor mediante datagramas con confirmación de recepción para poder ignorar los paquetes perdidos.

Dado que se requieren seis paquetes para completar este protocolo, tal vez se pregunte por qué no utilizar mejor un protocolo sin conexión. La respuesta es que en un mundo perfecto podría ser así, en cuyo caso sólo se necesitarían dos paquetes: uno para la petición y otro para la respuesta. Pero cuando hay mensajes extensos en cualquier dirección (por ejemplo, un archivo de un megabyte), errores de transmisión y paquetes perdidos, la situación cambia. Si la respuesta consistiera de cientos de paquetes, algunos de los cuales se pudieran perder durante la transmisión, ¿cómo sabría el cliente que faltan algunas piezas?, ¿cómo sabría si el último paquete que se recibió fue en realidad el último paquete enviado? Suponga que el cliente desea un segundo archivo. ¿Cómo podría diferenciar el paquete 1 del segundo archivo de un paquete 1 perdido del primer archivo que por fin pudo llegar al cliente? En resumen, en el mundo real es inadecuado usar un protocolo simple de petición-respuesta a través de una red poco confiable. En el capítulo 3 estudiaremos con detalle una variedad de protocolos que solucionan éstos y otros problemas. Por el momento basta con decir que algunas veces es conveniente tener un flujo de bytes ordenado y confiable entre procesos.

1.3.5 La relación entre servicios y protocolos

Los servicios y los protocolos son conceptos distintos. Esta distinción es tan importante que la enfatizaremos una vez más. Un *servicio* es un conjunto de primitivas (operaciones) que una capa proporciona a la capa que está encima de ella. El servicio define qué operaciones puede realizar la capa en beneficio de sus usuarios, pero no dice nada sobre cómo se implementan estas operaciones. Un servicio se relaciona con una interfaz entre dos capas, en donde la capa inferior es el proveedor del servicio y la capa superior es el usuario.

En contraste, un *protocolo* es un conjunto de reglas que rigen el formato y el significado de los paquetes o mensajes que intercambian las entidades iguales en una capa. Las entidades utilizan protocolos para implementar sus definiciones de servicios. Pueden cambiar sus protocolos a voluntad, siempre y cuando no cambien el servicio visible para sus usuarios. De esta manera, el servicio y el protocolo no dependen uno del otro. Éste es un concepto clave que cualquier diseñador de red debe comprender bien.

Para repetir este punto importante, los servicios se relacionan con las interfaces entre capas, como se muestra en la figura 1-19. En contraste, los protocolos se relacionan con los paquetes que se envían entre las entidades pares de distintas máquinas. Es muy importante no confundir los dos conceptos.




Figura 1-19. La relación entre un servicio y un protocolo.

Vale la pena mencionar una analogía con los lenguajes de programación. Un servicio es como un tipo de datos abstracto o un objeto en un lenguaje orientado a objetos. Define las operaciones que se pueden realizar en un objeto, pero no especifica cómo se implementan estas operaciones. En contraste, un protocolo se relaciona con la *implementación* del servicio y como tal, no es visible al usuario del mismo.

Muchos protocolos antiguos no diferenciaban el servicio del protocolo. En efecto, una capa típica podría tener una primitiva de servicio SEND PACKET en donde el usuario proporcionaba un apuntador hacia un paquete completamente ensamblado. Este arreglo significaba que los usuarios podían ver de inmediato todos los cambios en el protocolo. Ahora, la mayoría de los diseñadores de redes consideran dicho diseño como un error garrafal.

1.4 MODELOS DE REFERENCIA

Ahora que hemos analizado en lo abstracto las redes basadas en capas, es tiempo de ver algunos ejemplos. Analizaremos dos arquitecturas de redes importantes: el modelo de referencia OSI y el modelo de referencia TCP/IP. Aunque ya casi no se utilizan los *protocolos* asociados con el modelo OSI, el *modelo* en sí es bastante general y sigue siendo válido; asimismo, las características en cada nivel siguen siendo muy importantes. El modelo TCP/IP tiene las propiedades opuestas: el modelo en sí no se utiliza mucho, pero los protocolos son usados ampliamente. Por esta razón veremos ambos elementos con detalle. Además, algunas veces podemos aprender más de los fracasos que de los éxitos.

1.4.1 El modelo de referencia OSI

El modelo OSI se muestra en la figura 1-20 (sin el medio físico). Este modelo se basa en una propuesta desarrollada por la Organización Internacional de Normas (ISO) como el primer paso hacia la estandarización internacional de los protocolos utilizados en las diversas capas (Day y Zimmerman, 1983). Este modelo se revisó en 1995 (Day, 1995) y se le llama **Modelo de referencia OSI (Interconexión de Sistemas Abiertos)**, del inglés *Open Systems Interconnection*) de la ISO puesto que se ocupa de la conexión de sistemas abiertos; esto es, sistemas que están abiertos a la comunicación con otros sistemas. Para abreviar, lo llamaremos **modelo OSI**.

El modelo OSI tiene siete capas. Los principios que se aplicaron para llegar a las siete capas se pueden resumir de la siguiente manera:

1. Se debe crear una capa en donde se requiera un nivel diferente de abstracción.
2. Cada capa debe realizar una función bien definida.
3. La función de cada capa se debe elegir teniendo en cuenta la definición de protocolos estandarizados internacionalmente.